



Monitoreo Transaccional: El Valor del Orden

Informe Ejecutivo para el Comité de Riesgos
Banco del Altiplano

Integrantes:

Jonathan Zacarías (Carné 231104)

Luis Gilberto (Carné 23353)

Curso: Deep Learning 2026

Universidad del Valle de Guatemala

4 de septiembre de 2026

1. Resumen e integridad de los datos

El modelo secuencial B obtiene mejores resultados que la línea base A en la simulación: AUC-PR de 0.998430 frente a 0.981534 y un ahorro mensual proyectado de Q641,520. La permutación reduce su AUC-PR a 0.2564. Esto muestra sensibilidad a la disposición de los eventos, pero el experimento todavía no aísla completamente el valor causal del orden.

Decisión propuesta. Conservar el motor actual y evaluar B como complemento en un piloto con datos reales. Los resultados sintéticos no justifican todavía un reemplazo automático.

Origen, unidad de análisis y tamaño

Se utilizó la Ruta A: generador propio con semilla 42, 1,200 clientes y 90 días simulados desde el 1 de enero de 2026. Se obtuvieron 214,252 transacciones, de las cuales 19,699 son fraudulentas: una tasa observada de 9.1943%. El parámetro 3.5% activa episodios; cada episodio puede producir varias transacciones fraudulentas, por lo que no equivale a la prevalencia final.

Tabla 1. Partición temporal y prevalencia observada

Partición	Transacciones	Fraudes	Tasa de fraude
Entrenamiento: 60 días	142,170	12,916	9.0849%
Validación: 15 días	35,897	3,327	9.2682%
Prueba: tramo final	36,185	3,456	9.5509%

Los cortes exactos son el 2 y el 17 de marzo de 2026, a las 00:58:44.863233, calculados desde la primera transacción. Prueba termina el 31 de marzo. Cada ejemplo predice si la transacción actual es fraudulenta, usando esa operación y hasta cinco anteriores del mismo cliente ($K = 6$); las ventanas incompletas se rellenan a la izquierda con ceros.

Tres fraudes y un caso legítimo difícil

Sondeo y vaciado. Tres compras de Q5 a Q25 preceden una de Q3,500 a Q8,500; se etiquetan como fraude también los sondeos.

Cambio de canal y velocidad. Ráfagas de dos o tres operaciones online internacionales de Q800 a Q2,200.

Pico de monto. Operación aislada de Q4,000 a Q9,500, como control que puede detectarse sin secuencia.

Viaje legítimo. Gastos internacionales de Q2,500 a Q6,000 con etiqueta legítima; permiten medir bloqueos indebidos. No constituyen un cuarto fraude.

Controles: los agregados históricos usan eventos anteriores; los escaladores y vocabularios se ajustan solo en entrenamiento. Las secuencias se construyen por separado en cada partición, de modo que pierden contexto previo al corte. El promedio histórico es acumulado, no una ventana fija de 60 días.

2. Comparación común de los modelos

A, B y C puntúan las mismas 36,185 transacciones de prueba y predicen la misma etiqueta actual. La métrica principal es el área bajo la curva precisión-exhaustividad (AUC-PR), calculada mediante integración trapezoidal. Precisión, exhaustividad y F1 se reportan con los umbrales elegidos en validación.

A: línea base tabular. MLP con capas de 64 y 32 unidades sobre 12 variables de monto, razones y resúmenes históricos. Incluye tiempo desde la operación anterior, hora y día; no procesa una lista ordenada, aunque sí recibe información temporal resumida.

B: modelo secuencial. LSTM de dos capas y 64 unidades, con cuatro variables numéricas por evento y representaciones aprendidas de comercio y canal.

C: apuesta híbrida. Combina una rama LSTM con una rama MLP de agregados y produce un solo puntaje de riesgo.

Tabla 2. Desempeño en prueba con umbrales fijados en validación

Modelo	Umbral	AUC-PR	Precisión	Exhaust.	F1
A: agregado	0.554444	0.981534	0.702289	0.994502	0.823234
B: secuencial	0.683131	0.998430	0.973239	0.999711	0.986297
C: híbrido	0.089192	0.998151	0.974323	0.999132	0.986571

B mejora el AUC-PR en 0.016896 y el F1 en 0.163063 frente a A. Su precisión pasa de 70.2289% a 97.3239%, manteniendo una exhaustividad de 99.9711%. C tiene un F1 ligeramente mayor que B, pero menor AUC-PR y mayor costo en prueba.




Figura 1. Curvas precisión-exhaustividad y ROC conservadas en el notebook. Las leyendas redondean a tres decimales; la Tabla 2 conserva seis.

Qué controla la comparación y qué falta aislar

Se entrenó con pérdida ponderada para fraude, AdamW y selección de pesos por AUC-PR de validación: A durante 20 épocas; B y C durante 25. Los umbrales se seleccionaron después. B también recibe comercio y canal, variables que A no incorpora explícitamente; por ello, la brecha A-B no mide exclusivamente el efecto del orden.

3. Valor del orden: pruebas de falsificación

3.1. Permutación controlada del modelo B

Se evaluó B con sus pesos y umbral fijos después de barajar las seis posiciones de cada ventana. Las variables numéricas, comercio y canal se desplazan juntas; no se cambia el conjunto de eventos. El procedimiento utiliza una permutación compartida por lote y conserva los valores de los intervalos temporales originales.

Tabla 3. Resultado guardado de la permutación de B

Condición	AUC-PR	F1
Orden original	0.9984	0.9863
Orden barajado	0.2564	0.4203
Disminución absoluta	0.7420	0.5660

El AUC-PR cae 74.3% respecto del orden original. La magnitud respalda que B depende de cómo se presentan los eventos. Sin embargo, la prueba también mueve la transacción objetivo fuera de la última posición y desplaza el relleno de ceros. La caída puede combinar pérdida de orden con pérdida de la ubicación esperada de la operación que se intenta clasificar.

Alcance de la conclusión. Hay evidencia de sensibilidad a la secuencia; no una demostración causal definitiva. El siguiente control debe fijar la transacción actual y el relleno, permutar solo la historia y repetir con varias semillas. También debe igualar las variables disponibles para A y B.

3.2. Caso legítimo difícil: gastos durante viajes

La segunda prueba efectivamente guardada mide falsos positivos sobre 67 transacciones legítimas de viaje en prueba, correspondientes a 28 clientes al reproducir el generador. No es un desglose de exhaustividad por mecanismo de fraude.

Tabla 4. Bloqueos indebidos en el subconjunto de viaje legítimo

Modelo	Bloqueadas / 67	Tasa de bloqueo
A: agregado	20 / 67	29.8507%
B: secuencial	2 / 67	2.9851%
C: híbrido	1 / 67	1.4925%

B evita 18 bloqueos de viaje frente a A, equivalentes a Q3,240 en ese subconjunto; C evita 19, equivalentes a Q3,420. Estos montos forman parte del costo total y no deben sumarse nuevamente al ahorro de la sección 5.

Patrón de error concreto. B aún bloquearía 2 operaciones legítimas de viaje. La métrica correcta aquí es la tasa de falsos positivos; un recall de fraude igual a cero en una muestra sin fraudes no demostraría ausencia de errores.

Esta prueba respalda menor fricción en el caso simulado, pero contiene pocos eventos, varios del mismo cliente. No demuestra por sí sola el valor del orden ni informa qué mecanismo concentra los falsos negativos. El notebook no conserva resultados de recall por cada tipo de fraude.

4. Apuesta C: hipótesis, control y veredicto

Hipótesis documentada antes del entrenamiento

La celda de hipótesis propone que combinar agregados históricos con los últimos seis eventos mejorará el AUC-PR y el costo frente a B, porque ambas entradas representan escalas de comportamiento distintas. Plantea evaluarlo en validación, sin elevar el costo ni los falsos positivos de viaje. Sin embargo, el mínimo de mejora permanece escrito como “X puntos porcentuales”, sin un valor definido.

Control previsto. Se conserva la partición temporal y el procedimiento de entrenamiento y selección del umbral. B es el comparador descrito en la hipótesis. C añade a B la rama de agregados; por tanto, cambia tanto la arquitectura como la información histórica disponible para el modelo completo.

Resultados observados frente al control B

Tabla 5. Comparación de C respecto de B

Indicador	B	C	Cambio C – B
AUC-PR en prueba	0.998430	0.998151	–0.000279
F1 en prueba	0.986297	0.986571	+0.000274
Costo de validación	Q18,240	Q18,060	–Q180
Costo de prueba	Q21,300	Q28,980	+Q7,680
Bloqueos de viaje en prueba	2 de 67	1 de 67	–1 bloqueo

C reduce un bloqueo de viaje y mejora marginalmente el F1, pero no mejora el AUC-PR ni el costo en prueba frente a B. El menor costo de validación de C por Q180 no se mantiene en el período final. No se guardan los AUC-PR finales de validación ni los bloqueos de viaje de validación necesarios para contrastar íntegramente la hipótesis original.

Inconsistencia del criterio en las conclusiones

La última celda cambia el comparador a A y aplica una mejora de AUC-PR de al menos 0.05, además de ahorro de Q15,000 mensuales o reducción de costo de 15%. Es un criterio distinto del formulado antes de entrenar y no puede presentarse como una regla previamente fijada.

Bajo esa regla final, C mejora el AUC-PR frente a A en 0.016617 y reduce el costo 91.5278%, con Q626,160 de ahorro mensual simulado: cumple la parte financiera y falla la técnica. Con A en 0.981534, el margen máximo hasta 1 es 0.018466, inferior a 0.05. Esto explica el fallo de esa regla, pero no valida retrospectivamente su definición.

Veredicto. La hipótesis previa queda incompletamente especificada y no puede declararse confirmada. Los resultados de prueba no muestran una ventaja económica de C sobre B. Antes de otro experimento se debe fijar el comparador, el mínimo de mejora y el criterio financiero, y reservar un nuevo período de prueba.

La mayor complejidad de C se desprende de sus dos ramas; la latencia y el costo de operación no fueron medidos. Tampoco se evaluaron las arquitecturas alternativas mencionadas en el notebook, por lo que no se les atribuyen resultados comparativos.

5. Decisión económica y recomendación

La decisión penaliza cada fraude no detectado (FN) con Q4,200 y cada bloqueo legítimo (FP) con Q180. Para cada modelo se probaron 100 umbrales entre 0.01 y 0.99, y se eligió el menor costo en validación. Se bloquea cuando el puntaje es mayor o igual al umbral.

$$\text{Costo} = Q4,200 \times \text{FN} + Q180 \times \text{FP}$$

Tabla 6. Errores y costo en las 36,185 transacciones de prueba

Modelo	Umbral	FN	FP	Costo prueba	Costo × 2
A a 0.50	0.500000	12	1,517	Q323,460	Q646,920
A ajustado	0.554444	19	1,457	Q342,060	Q684,120
B secuencial	0.683131	1	95	Q21,300	Q42,600
C híbrido	0.089192	3	91	Q28,980	Q57,960

FN y FP se reconstruyen de las métricas y costos guardados, sobre 3,456 fraudes y 32,729 operaciones legítimas. Por ejemplo, B: $1 \times Q4,200 + 95 \times Q180 = Q21,300$. Los costos mínimos de validación fueron Q310,500 para A, Q18,240 para B y Q18,060 para C.

Umbral propuesto para el piloto de B. 0.683131, el valor seleccionado en validación. No se reajusta con la prueba. A calibrado cuesta Q18,600 más que A a 0.50 en prueba: un óptimo de validación no garantiza el menor costo futuro.

Proyección mensual de la simulación

Se conserva la convención del notebook: factor $30/15 = 2$. Para B frente a A: $(Q342,060 - Q21,300) \times 2 = Q641,520$ mensuales. C ahorra Q626,160 frente a A; B ahorra Q604,320 frente a A a 0.50. B cuesta Q15,360 menos al mes que C en esta extrapolación.

El factor equivale a 72,370 transacciones por mes al volumen simulado. Es una aproximación del tramo final a 15 días y supone volumen, prevalencia y errores estables. No representa el ahorro de 1.4 millones de tarjetas: faltan el flujo real del banco y los costos de implementación, revisión e inferencia.

6. Recomendación, límites y condición de cambio

Recomendamos conservar el sistema actual y probar B como complemento, primero sin bloquear automáticamente. B tiene el menor costo observado en prueba, pero escogerlo por ese resultado es una recomendación exploratoria: requiere confirmación en datos posteriores. C tuvo menor costo en validación, lo que refuerza la necesidad de ese control.

B todavía omite 1 fraude y bloquea 95 operaciones legítimas, incluidas 2 de viaje. No se conoce el mecanismo de ese falso negativo. Las métricas cercanas a 1 pueden reflejar patrones y asociaciones artificialmente fáciles del generador; tampoco se han probado fraudes nuevos, deriva o clientes no vistos.

Consideraríamos el reemplazo solo si B mantiene menor costo neto que el motor vigente en un período real posterior, con umbral y criterios fijados de antemano, y si los controles corregidos sostienen el valor del orden. Si desaparece esa ventaja, aumentan los bloqueos legítimos o los costos operativos absorben el ahorro, se conserva el motor actual.

Matriz de evidencias

Las seis evidencias exigidas por el proyecto se localizan a continuación. Las conclusiones se limitan a lo que puede verificarse en el notebook entregado.

Evidencia	Figura o tabla	Conclusión	Limitación
Integridad de datos	Tabla 1; sección 1	214,252 transacciones; fraude observado 9.1943%; cortes temporales.	Datos sintéticos; contexto secuencial reiniciado en cada partición.
Comparación común A-B	Tabla 2; Figura 1	B: AUC-PR 0.998430 y F1 0.986297; superiores a A.	B incorpora comercio y canal; la comparación no aísla solo el orden.
Valor del orden y segunda prueba	Tablas 3 y 4; sección 3	AUC-PR de B cae 74.3%; bloquea 2 de 67 viajes, frente a 20 de A.	Permutación mueve objetivo y relleno; caso de viaje pequeño y sintético.
Apuesta del equipo	Tabla 5; sección 4	C no mejora AUC-PR ni costo de prueba frente a B.	Hipótesis deja X sin definir; conclusión cambia de B a A.
Decisión económica	Tabla 6; sección 5	B usa umbral 0.683131; ahorro simulado Q641,520/mes frente a A.	Factor mensual aproximado; no incluye operación ni escala real del banco.
Recomendación y límites	Tabla 6; sección 6	Conservar motor vigente y pilotear B como complemento.	Candidato sugerido tras observar prueba; requiere período independiente.

Fuentes y trazabilidad

[1] **Notebook principal.** proyecto1_monitoreo_transaccional(1).ipynb. Fuente del generador, preparación, arquitecturas, resultados, umbrales, permutación, prueba de viaje e impacto económico. Se priorizan sus salidas guardadas sobre las cifras del informe y de la presentación anteriores.

[2] **Enunciado.** Proyecto_1_Monitoreo_Transaccional.pdf. Define las seis evidencias, las dos pruebas de falsificación, la función de costo y el límite de siete páginas.

[3] **Carátula.** informe_final_bn_caratula(1).pdf, página 1. Reproducida íntegramente, con su logo, título, integrantes y fecha.

Alcance de la verificación

Se reprodujo el generador con semilla 42 para comprobar tamaños, prevalencias, fechas y los 28 clientes que concentran las 67 operaciones de viaje. Las métricas de modelos provienen de los resultados conservados; no se reentrenaron redes ni se generaron predicciones nuevas para este informe. Se verificaron aritméticamente costos, diferencias y proyecciones.

Las celdas de permutación, viaje e impacto económico conservan salidas aunque carecen de contador de ejecución. Una ejecución limpia y completa debe confirmar su trazabilidad. La documentación también debe corregir la hipótesis de C antes de un nuevo experimento; no es válido completar retrospectivamente el criterio X con resultados de prueba.

El informe no acredita la exportación de pesos, parámetros de preparación ni README, entregables adicionales del proyecto que no forman parte de los archivos aquí revisados.